

Pasos seguidos de la limpieza y preparación del dataset final de trabajo

Luego de finalizar el proceso de extracción de datos con el CSV generado, creé la estructura del bucket en Amazon S3 donde almacenaré los datos en bruto (raw/) y los datos limpios (silver/).

The screenshot shows the AWS S3 console interface. The top navigation bar includes the AWS logo, a search bar, and a dropdown menu for the region (Estados Unidos (Norte de Virginia)). The breadcrumb trail indicates the current location: Amazon S3 > Buckets > analisis-productos-alimenticios-data.

The main section is titled 'analisis-productos-alimenticios-data' with a sub-tab 'Información'. Below this, there are several tabs: 'Objetos', 'Metadatos', 'Propiedades', 'Permisos', 'Métricas', 'Administración', 'Sistemas de archivos: nuevos', and 'Punto de acceso'. The 'Objetos' tab is selected, showing a list of objects.

The 'Objetos' tab displays a list of objects with columns: 'Nombre', 'Tipo', 'Última modificación', and 'Tamaño'. The objects listed are 'raw/' and 'silver/', both of type 'Carpeta' (Folder).

Below the object list, there is a section for the 'raw/' prefix. It shows a list of objects with columns: 'Nombre', 'Tipo', 'Última modificación', 'Tamaño', and 'Clase de almacenamiento'. The object listed is 'dataset_productos_en_bruto.csv', of type 'csv', with a size of 289.3 KB and a storage class of 'Estándar'.

Creé un AWS Glue Crawler y lo ejecuté sobre el archivo subido a la carpeta raw/

The screenshot shows the AWS Glue console interface. The top navigation bar includes the AWS logo, a search bar, and a dropdown menu for the region (Estados Unidos (Norte de Virginia)). The breadcrumb trail indicates the current location: AWS Glue > Crawlers.

The main section is titled 'Crawlers (1)' with a sub-tab 'Info'. Below this, there are several tabs: 'Crawlers', 'Jobs', 'Tables', 'Connections', 'Resolvers', 'DevEndpoints', and 'Tables'. The 'Crawlers' tab is selected, showing a list of crawlers.

The 'Crawlers' tab displays a list of crawlers with columns: 'Name', 'State', 'Schedule', 'Last run', 'Last run ti...', 'Log', and 'Table change...'. The crawler listed is 'crawler-datos-...', with a state of 'Ready' and a last run status of 'Succeeded'.

Con esto pude verificar si el servicio detectó correctamente el tipo de datos de cada columna.

Schema (15)

View and manage the table schema.

Filter schemas			
#	▼	Column name	▼ Data type
1		id_producto	double
2		ean	bigint
3		nombre	string
4		categoria	string
5		marca	string
6		precio_empaque	double
7		precio_por_kilo	double
8		calorias_100g	double
9		proteinas_100g	double
10		fibra_100g	double
11		grasa_saturada_100g	double
12		azucar_100g	double
13		sal_100g	string
14		nutri_score	string
15		procesado	bigint

Una vez creada la tabla de metadatos a través del Crawler, ejecuté la función de generación automática de estadísticas de AWS Glue. Esta herramienta es muy útil para visualizar valores nulos, su concentración por columna e identificar *outliers* rápidamente. Por ejemplo, un producto con 5000 calorías por cada 100 g no es real, por lo tanto, sabemos que es un error de origen. También verifiqué que ningún componente nutricional medido por cada 100 g (como azúcares o grasas) superara los 100 g, lo cual evidenciaría un fallo en los datos de las APIs.

Considerando lo anterior, el análisis estadístico previo me permitió diseñar mejores consultas en Amazon Athena para profundizar en estos problemas (principalmente nulos y *outliers*) antes de desarrollar el script de limpieza definitivo.

Column statistics (14) Info

Get an overview of the data profile. We estimate the approximate number of distinct values in a data set with 5% average relative error.

Find columns

Column name	Average le...	Distinct va...	Max length	Null values	Max value	Min value
azucar_100g	-	318	-	829	100	0
calorias_100g	-	739	-	754	5232.87671232	0
categoria	12.90	264	32	0	-	-
ean	-	2434	-	0	9012200872735	80177173
fibra_100g	-	178	-	1578	57	0
grasa_saturada_100g	-	259	-	837	95	0
id_producto	-	2594	-	0	92998	1564
marca	7.41	137	23	0	-	-
nombre	36.53	2319	106	0	-	-
nutri_score	2.17	8	14	0	-	-
precio_empaque	-	414	-	0	1282.05	0.18
precio_por_kilo	-	890	-	0	4875	0.01
proteinas_100g	-	320	-	766	89	0
sal_100g	2.86	423	18	0	-	-

Consulta en Amazon Athena para identificar qué categorías agrupan la mayor cantidad de valores nulos.

Amazon Athena > Editor de consultas

Editor

Consultas recientes

Consultas guardadas

Configuración de consultas

Grupo

Datos

Origen de datos

AwsDataCatalog

Catálogo

Ningún elemento

Base de datos

db-productos-alimenticios

Consulta 1

Consulta 2

```
1 SELECT categoria,
2     COUNT(CASE WHEN fibra_100g IS NULL THEN 1 END) AS nulos_fibra,
3     COUNT(CASE WHEN calorias_100g IS NULL THEN 1 END) AS nulos_calorias,
4     COUNT(CASE WHEN fibra_100g IS NULL OR calorias_100g IS NULL THEN 1 END) AS nulos_cualquiera,
5     COUNT(*) AS total_productos
6 FROM "db-productos-alimenticios"."raw"
7 GROUP BY categoria
8 order by ;
```

Completado

Tiempo en cola: 105 ms

Tiempo de ejecución: 772 ms

Datos analizados: 289.34 KB

Resultados (262)

Copiar

Descargar resultados en formato CSV

Filas de búsqueda

#	categoria	nulos_fibra	nulos_calorias	nulos_cualquiera	total_productos
1	Pollo	37	32	37	38
2	Cerdo	30	26	30	31
3	Pescado	25	14	25	27
4	Pizzas refrigeradas	21	0	21	23
5	Queso curado	20	17	20	21
6	Bollería dulce	20	20	20	26
7	Pavo y otros	19	0	19	22
8	Leche semidesnatada	19	1	19	21
9	Leche desnatada	19	3	19	21
10	Enchufados	18	11	18	21

Ejecuté una consulta en Amazon Athena para identificar qué categorías presentaban más de un 70% de valores nulos en la columna `calorias_100g`. Este paso es fundamental, ya que este dato es crítico para el análisis. Decidí excluir estas categorías debido a que corresponden a productos no útiles (como velas) o a productos no envasados que carecen de información nutricional en las APIs de origen.

Consulta 1 ✕

✓ Consulta 2 ✕

```
1 SELECT categoria,
2     COUNT(CASE WHEN calorias_100g IS NULL THEN 1 END) AS nulos_calorias,
3     COUNT(*) AS total_productos
4 FROM "db-productos-alimenticios"."raw"
5 GROUP BY categoria
6 HAVING (COUNT(CASE WHEN calorias_100g IS NULL THEN 1 END) * 100.0 / COUNT(*)) >= 70.0
7 ORDER BY total_productos DESC;
```

✓ Completado

Tiempo en cola: 95 ms

Tiempo de ejecución: 665 ms

Datos analizados: 289.34 KB

Resultados (56)

Copiar

Descargar resultados en formato CSV

Q Filas de búsqueda

< 1 > ⚙

#	▼	categoria	▼	nulos_calorias	▼	total_productos	▼
1		Pollo		32		38	
2		Cerdo		26		31	
3		Bollería dulce		20		26	
4		Queso curado		17		21	
5		Otras verduras y hortalizas		16		18	
6		Otras especias		15		16	
7		Bollería salada		9		11	
8		Pastelitos surtidos		11		11	
9		Otras frutas		11		11	
10		Velas		11		11	

Identificación de las categorías que presentan un 100% de valores nulos, las cuales deben ser eliminadas por completo del análisis final.

Consulta 1 : ✕ | **Consulta 2 : ✕**

```
1 SELECT categoria,
2     COUNT(CASE WHEN calorías_100g IS NULL THEN 1 END) AS nulos_calorias,
3     COUNT(*) AS total_productos
4 FROM "db-productos-alimenticios"."raw"
5 GROUP BY categoria
6 HAVING COUNT(CASE WHEN calorías_100g IS NULL THEN 1 END) = COUNT(*)
7 ORDER BY total_productos DESC;
```

Completado | Tiempo en cola: 98 ms | Tiempo de ejecución: 891 ms | Datos analizados: 289.34 KB

Resultados (39) | Copiar | Descargar resultados en formato CSV

Filas de búsqueda

#	▼	categoria	▼	nulos_calorias	▼	total_productos	▼
1		Otras frutas		11		11	
2		Velas		11		11	
3		Pastelitos surtidos		11		11	
4		Salmón		10		10	
5		Hierbas		10		10	
6		Fruta tropical		9		9	
7		Manzana y pera		9		9	
8		Pañal talla de 4 a XL		8		8	
9		Queso semicurado		7		7	
10		Braguita y otros		7		7	

Con base en estos resultados, generé la siguiente lista negra de categorías a eliminar en el proceso de transformación:

lista_negra_total = ["Velas", "Pañal talla de 4 a XL", "Braguita y otros", "Toallitas", "Pañal talla de 0 a 3", "Accesorios", "Biberón", "Chupete", "Aceite y crema", "Champú y jabón", "Colonia", "Cápsulas compatibles Tassimo", "Hierbas", "Colorante y pimentón", "Hielo"]

Diseño de consultas en Amazon Athena para la detección de valores atípicos (*outliers*).

Consulta 1 : ✕

✓ Consulta 2 : ✕

1

SELECT nombre,ean,calorias_100g

2

FROM "db-productos-alimenticios"."raw"

3

where calorias_100g > 900

4

ORDER BY calorias_100g DESC;

✓ Completado

Tiempo en cola: 147 ms

Tiempo de ejecución: 534 ms

Datos analizados: 289.34 KB

Resultados (2)

Copiar

Descargar resultados en formato CSV

Q Filas de búsqueda

< 1 >

⚙

#	nombre	ean	calorias_100g
1	Pan tostado 100% espelta integral Hacendado	8480000828422	5232.87671232877
2	Café soluble cappuccino caramelo Hacendado	8480000676603	2821.42857142857

Asimismo, validé que ningún componente superara los 100 g por porción, ya que lógicamente un producto no puede contener, por ejemplo, más de 100 g de sal en una muestra de 100 g. Esta regla de negocio se aplicó a todas las métricas nutricionales.

Consulta 1 : ✕

✓ Consulta 2 : ✕

✓ Consulta 3 : ✕

1

SELECT nombre, ean, proteinas_100g, fibra_100g, grasa_saturada_100g, azucar_100g, sal_100g

2

FROM "db-productos-alimenticios"."raw"

3

WHERE proteinas_100g > 100

4

OR fibra_100g > 100

5

OR grasa_saturada_100g > 100

6

OR azucar_100g > 100

7

OR (sal_100g IS NOT NULL AND sal_100g != '' AND CAST(sal_100g AS DOUBLE) > 100);

8

✓ Completado

Tiempo en cola: 106 ms

Tiempo de ejecución: 757 ms

Datos analizados: 289.34 KB

Resultados (0)

Copiar

Descargar resultados en formato CSV

Q Filas de búsqueda

< 1 >

⚙

#	nombre	ean	proteinas_100g	fibra_100g	grasa_saturada_100g	azucar_100g	sal_100g
---	--------	-----	----------------	------------	---------------------	-------------	----------

No hay resultados

Ejecución del script de AWS Glue.

limpieza_dataset

Last modified on 13/6/2026, 1

Script

Job details

Runs

Data quality

Schedules

Version Control

Script

Info

```
18 df = spark.read.option("header", "true").option("delimiter", ";").csv("s3://analisis-productos-alimenticios-data/raw/")
19
20 lista_categorias_descartadas = [
21     "Velas", "Pañal talla de 4 a XL", "Braguita y otros", "Toallitas",
22     "Pañal talla de 0 a 3", "Accesorios", "Biberón", "Chupete",
23     "Aceite y crema", "Champú y jabón", "Colonia",
24     "Cápsulas compatibles Tassimo", "Hierbas", "Colorante y pimentón", "Hielo"
25 ]
26 ean_productos_eliminar = [8480000828422, 8480000676603]
27
28 df_columnas_importantes = df.filter(~F.col("categoria").isin(lista_categorias_descartadas))
29 df_columnas_importantes = df_columnas_importantes.filter(~F.col("ean").isin(ean_productos_eliminar))
30
31 df_filtrado = df_columnas_importantes
32
33 columnas_nutricionales = ["calorias_100g", "proteinas_100g", "azucar_100g", "fibra_100g", "grasa_saturada_100g", "sal_100g"]
34 for col_name in columnas_nutricionales:
35     df_filtrado = df_filtrado.withColumn(col_name, F.col(col_name).cast("double"))
36
37 df_filtrado = df_filtrado.withColumn(
```

Python

Ln 1, Col 1

Errors: 0

Warnings: 0

Finalmente, verifiqué la correcta creación y almacenamiento de los archivos en formato Parquet dentro de la capa silver/ de Amazon S3.

silver/

Objetos

Propiedades

Objetos (1)

Copiar URI de S3

Copiar URL

Descargar

Abrir

Eliminar

Acciones

Crear carpeta

Los objetos son las entidades fundamentales que se almacenan en Amazon S3. Puede utilizar el [inventario de Amazon S3](#) para obtener una lista de todos los objetos de su bucket. Para que otras personas obtengan acceso a sus concederles permisos de forma explícita. [Más información](#)

Buscar objetos por prefijo

☐	Nombre	Tipo	Última modificación	Tamaño	Clase de almacenamiento
☐	part-00000-98b98d2f-ab1d-4e72-a990-05f9b0f52807-c000.snappy.parquet	parquet	13 Jun 2026 6:48:09 PM CEST	126.8 KB	Estándar

Posteriormente, volví a ejecutar el Glue Crawler sobre la carpeta silver/ para actualizar el catálogo de datos. Esto me permitió realizar consultas de auditoría en Amazon Athena y comprobar que los registros irrelevantes y los *outliers* detectados se eliminaron correctamente, evitando distorsiones en los análisis posteriores.

Schema (15)

View and manage the table schema.

#	▼	Column name	▼	Data type
1		id_producto		double
2		ean		bigint
3		nombre		string
4		categoria		string
5		marca		string
6		precio_empaque		double
7		precio_por_kilo		double
8		sal_100g		double
9		nutri_score		string
10		calorias_100g		double
11		proteinas_100g		double
12		fibra_100g		double
13		grasa_saturada_100g		double
14		azucar_100g		double
15		procesado		struct

Al revisar el esquema generado, detecté una anomalía técnica: la columna procesado fue tipada como struct. Esto ocurrió debido a que la extracción de la API original inyectaba dos llaves vacías {} en los registros sin datos, lo que confundió al inferidor del Crawler, interpretándolo como un objeto compuesto en lugar de un entero.

Para solucionar esto, modifiqué el script de PySpark para leer directamente el CSV original. Esto me permitió realizar un mapeo explícito de tipos y reemplazar las llaves {} por valores nulos (None) directamente en el código. Con este tipado estricto, aseguré que la herramienta de estadísticas de AWS Glue procesara la información de manera correcta.

Finalmente, reejecuté el Crawler sobre el dataset limpio para generar el esquema definitivo y actualizar las estadísticas de la columna. Así validé visualmente la remoción total de las categorías no deseadas y los valores atípicos.

Schema (15)

View and manage the table schema.



#	Column name	Data type
1	id_producto	string
2	ean	string
3	nombre	string
4	categoria	string
5	marca	string
6	precio_empaque	string
7	precio_por_kilo	string
8	calorias_100g	double
9	proteinas_100g	double
10	fibra_100g	double
11	grasa_saturada_100g	double
12	azucar_100g	double
13	sal_100g	double
14	nutri_score	string
15	procesado	int

Actualicé las estadísticas en AWS Glue para corroborar la calidad final del dato, confirmando la depuración exitosa de registros nulos y anomalías.

Column statistics (15) [Info](#)

Get an overview of the data profile. We estimate the approximate number of distinct values in a data set with 5% average relative error.



Column name	Average length	Distinct values	Max length	Null values	Max value	Min value
azucar_100g	-	318	-	749	100	0
calorias_100g	-	734	-	674	900	0
categoria	12.93	249	32	0	-	-
ean	13.00	2665	13	0	-	-
fibra_100g	-	178	-	1498	57	0
grasa_saturada_100g	-	259	-	757	95	0
id_producto	6.86	2481	7	0	-	-
marca	9.00	133	23	433	-	-
nombre	36.55	2261	106	0	-	-
nutri_score	2.81	7	14	542	-	-
precio_empaque	3.51	412	7	0	-	-
precio_por_kilo	3.84	792	6	0	-	-
procesado	-	4	-	1072	4	1
proteinas_100g	-	320	-	686	89	0
sal_100g	-	388	-	743	100	0

Posteriormente, descargué el archivo Parquet procesado a mi entorno local. Nota arquitectónica: Aunque la práctica ideal es conectar Power BI directamente a Amazon S3 o Athena, al utilizar una cuenta temporal de AWS Academy, la expiración de las credenciales interrumpiría el acceso al dashboard. Por lo tanto, opté por la descarga local para garantizar la persistencia del reporte.

part-00000-98b98d2f-ab1d-4e72-a990-05f9b0f52807-c000.snappy.parquet

categoria	marca	precio_empaque	precio_por_kilo	calorias_100g	proteinas_100g	fibra_100g	grasa_saturada_100g
Cocktails	Hacendado	1.6	5.33	498	14,8	7,9	
Levadura y preparado repostería	Hacendado	1.75	9.83	57	1,5	0	
Otros	Bosque Verde	2.2	0.02	null	null	null	
Lentejas y otros	Luengo	2.7	13.5	361	50	15	
Pepinillos y otros encurtidos	Hacendado	1.85	2.76	19	1,2	0,9	
Leche condensada y otros	Hacendado	1.66	2.77	50,93457944	7,4	null	
Otros sabores	Hacendado	1.05	1.05	18	0,4	0,4	
Salazones	Hacendado	1.7	21.25	280	16	null	
Atún	Hacendado	4.9	10.21	357	21	null	
Otros	Tivall	2.4	13.33	235	12,3	5,3	
Salchichón	Hacendado	1.85	7.71	462	16	null	
Con chocolate y rellenas	Hacendado	1.4	4.26	485,4368932	6,796116505	null	7,766990
Lechuga	null	2.0	0.33	13	0,98	null	
Salsas orientales	Hacendado	2.5	10.0	57	10		
Otros refrescos sin gas	Simon Life	1.85	1.23	20	0	null	

Durante el modelado, detecté una discrepancia en el formato regional: la API comercial utilizaba puntos como separadores decimales, mientras que la API nutricional utilizaba comas. Para homogeneizar el dataset bajo el estándar regional de España, apliqué una transformación para reemplazar los puntos por comas en las columnas comerciales.

```
= Parquet.Document(File.Contents("C:\Users\user\Desktop\proyecto github\parquet s3
```

A ^B C precio_empaque
1.6
1.75
2.2
2.7
1.85
1.66
1.05
1.7
4.9
2.4
1.85
1.4
null 2.0
2.5

Reemplazar los valores

Reemplace un valor con otro de las columnas seleccionadas.


Valor que buscar

Reemplazar con

► Opciones avanzadas

Al calcular el ratio de gramos de proteína por euro invertido, identifiqué una distorsión en productos comercializados en formato de paquete (*packs*). La API comercial registraba el peso total del paquete en lugar del peso por unidad o el


precio real por kilogramo. Esto alteraba la fórmula matemática empleada, sesgando el análisis de eficiencia económica.




Al ordenar el dataset de forma ascendente por la columna precio_por_kilo, localicé anomalías con valores extremadamente bajos, confirmando un error de etiquetado en la API de origen.

nombre	categoria	marca	precio_empaque	precio_por_kilo
Filtros de café para cafeteras tamaño 2 y 4 Bosque Verde	Otros	Bosque Verde	2,2	0,02
Café monodosis natural Hacendado	Monodosis	Hacendado	3	0,09
Huevos de codorniz	Huevos		1,85	0,1
Café monodosis descafeinado natural Hacendado	Monodosis	Hacendado	3,3	0,1
Café en cápsulas doble espresso Hacendado	Cápsulas compatibles Nespresso	Hacendado	3,8	0,19
Café en cápsula descafeinado Hacendado	Cápsulas compatibles Nespresso	Hacendado	3,85	0,19
Café en cápsula espresso Hacendado	Cápsulas compatibles Nespresso	Hacendado	3,8	0,19
Café en cápsula Colombia Hacendado	Cápsulas compatibles Nespresso	Hacendado	3,8	0,19
Café en cápsula ristretto Hacendado	Cápsulas compatibles Nespresso	Hacendado	3,8	0,19
Café en cápsula descafeinado espresso Hacendado	Cápsulas compatibles Nespresso	Hacendado	3,85	0,19
Café en cápsula extra fuerte Hacendado	Cápsulas compatibles Nespresso	Hacendado	3,8	0,19
Café en cápsula extra fuerte Hacendado	Cápsulas compatibles Dolce gusto	Hacendado	3,35	0,21
Café con leche en cápsula descafeinado Hacendado	Cápsulas compatibles Dolce gusto	Hacendado	3,35	0,21
Cortado en cápsula descafeinado Hacendado	Cápsulas compatibles Dolce gusto	Hacendado	3,35	0,21
Café con leche en cápsula Hacendado	Cápsulas compatibles Dolce gusto	Hacendado	3,35	0,21
Café en cápsula descafeinado Hacendado	Cápsulas compatibles Dolce gusto	Hacendado	3,35	0,21
Café cortado en cápsula Hacendado	Cápsulas compatibles Dolce gusto	Hacendado	3,35	0,21
Café en cápsula fuerte Hacendado	Cápsulas compatibles Dolce gusto	Hacendado	3,35	0,21
Café en cápsula doble espresso Hacendado	Cápsulas compatibles Dolce gusto	Hacendado	3,35	0,21
Café en cápsula classic Hacendado	Cápsulas compatibles Dolce gusto	Hacendado	3,35	0,21
Huevos	Huevos		5,6	0,23
Café en cápsula sabor Caramel Hacendado	Cápsulas compatibles Nespresso	Hacendado	2,4	0,24


Para corregir esta desviación y salvaguardar la integridad de los análisis posteriores, implementé una lógica condicional en Power Query. Diseñé una columna personalizada calculando el precio por kilo real mediante la siguiente fórmula:



Esta corrección fue crítica: un simple filtrado de valores atípicos habría eliminado registros valiosos de la muestra (como el caso de los huevos). Al recalcular el valor real en lugar de descartarlo, preservé la integridad del dataset. El resultado es un gráfico optimizado de eficiencia proteica/precio, listo para guiar decisiones inteligentes de compra.



Finalmente, apliqué filtros de exclusión para mitigar falsos positivos en el dashboard. Por ejemplo, productos como el café (con errores de etiquetado en la API) o los edulcorantes e infusiones mostraban ratios de proteína por caloría artificialmente altos debido a sus bajos aportes calóricos (p. 14). Analíticamente no tiene sentido sugerir el consumo de 100 g de edulcorante para alcanzar objetivos proteicos, por lo que restringí el análisis a productos con un aporte de proteína real superior a 5 g por cada 100 g.



Con estas etapas de limpieza concluidas, el dataset consolidado cuenta con la calidad y consistencia óptimas para proceder con el análisis avanzado en Power BI. El informe interactivo final se encuentra disponible en su respectiva carpeta dentro del repositorio.